Symposium2026 セッション「自由エネルギー原理から考える社会・心・AI」

野村 一行

導入　すれ違う会話から、心・社会・AIを考える

言葉は通じたのに、なぜ伝わらないのか

「仕事がうまくいかなくて」。友人にそう相談されたとします。解決策をいくつか提案したら、返事が途切れてしまった。後になって、助言よりも話を聞いてほしかったのかもしれない、と気づく。

言葉の意味が分かっても、相手が求めている応答まで分かるとは限りません。私たちは、表情や声、その人との関係を手がかりに意図を推測しています。問い返せば、思い違いが分かることもあります。理解は、相手とのやり取りの中でも変わるのです。

AIとの会話でも、回答は正しいのに、求めていた支援とは違うと感じる場面は考えられます。情報を返すことと、相手に合う応答を探ることの間には、どんな仕組みが必要なのでしょうか。

個人の理解から、社会の協調へ

本稿では「自由エネルギー原理」を出発点に、世界を知る仕組みから、心、対話、社会の秩序、言葉の共有、AI・ロボットとの協働へと考察を広げます。

ただし、これらが一つの原理からすべて説明済みというわけではありません。数理モデルで示せること、実験で確かめられたこと、そこからの解釈や提案は、分けて考えます。

相談で相手の意図を確かめることも、周囲の様子に応じて動き方を選ぶことも、理解と行動が結びつく場面です。その結びつきを考える出発点として、生物が環境の中で自らを維持する仕組みを見ていきます。

第1章　生物はどう環境に適応するのか――自由エネルギー原理

知覚・学習・行動に共通する原理を探す

暑ければ日陰へ移り、のどが渇けば水を探す。生物は、変化する環境の中で身体を維持しています。体温や水分量が生存できる範囲を外れれば、生き続けられません。そのためには、身体や周囲の状態を捉え、経験から学び、必要な行動を取ることが求められます。

カール・フリストンが提唱する自由エネルギー原理は、こうした知覚・学習・行動を、共通の数理的な枠組みで理解しようとするものです。生物が「変分自由エネルギー」という量を小さくするよう、内部状態や行動を変えると考えます。

「自由エネルギー」という名前に戸惑わないために

ここでいう自由エネルギーは、身体の燃料や、気持ちの余裕を測る量ではありません。感覚が生じる仕組みについてのモデルと、その原因についての推定を用いて計算する、情報に関わる量です。

ある感覚入力が、そのモデルのもとでどれほど起こりにくいかを表す尺度を「サプライズ」と呼びます。意識的に驚くこととは別の、統計的な尺度です。変分自由エネルギーは、このサプライズの上限になります。直接扱いにくいサプライズに代えて、変分自由エネルギーを使い、感覚の原因についての推定を改善すると考えます。

では、この量は何を評価するのでしょうか。観測をどれだけうまく説明できるかと、推定を事前の見込みからどれだけ変えるか。この二つの面から、変分自由エネルギーを表せます。後者を「複雑さ」と呼びますが、モデルの部品の数ではありません。確率分布は、どのような状態がどれほどありそうかを確率で表すものです。複雑さは、事前の見込みと、更新した推定を表す分布の違いを指します。観測を説明できさえすれば、推定をどれだけ変えてもよい、という評価にはなっていません。

このため、変分自由エネルギーは、予測と感覚のずれである「予測誤差」だけと常に同じではありません。また、自由エネルギーを小さくすることを「予測と違うものを、ひたすら避ける」と読めば、好奇心や探索を捉え損ねます。知らないものを調べる行動も、将来の不確かさを減らすうえで意味をもちます。

原理と、具体的な説明のモデル

この原理を掲げるだけでは、何を見て、どう動くかは決まりません。何を観測できるのか、何を推測するのか、身体や環境がどう変化するのかを、具体的なモデルとして定める必要があります。その説明が実際の生物に当てはまるかは、観察や実験に照らして検討します。

生物自身が意識して自由エネルギーの数値を計算している、という意味でもありません。数理的に記述できることと、それを脳や身体がどのように実現するかは、分けて問う必要があります。

生物が環境や身体について何を推定しているのかを具体的に考えるには、感覚が生じる仕組みを表す「生成モデル」が必要です。

第2章　世界をどう推測するのか――生成モデルと予測符号化

見えているものから、見えない原因を推測する

夕暮れの道で、遠くに人らしい影が見えます。誰かが立っているのか、それとも人の形をした看板なのか。輪郭がぼやけていて、すぐには判断できません。

目に届くのは、光の強さや色の分布です。「そこに人がいる」という答えが、そのまま入ってくるわけではありません。私たちは、届いた感覚を手がかりに、それを生じさせた原因を推測しています。この例では、人か看板かという対象の種類、距離、明るさなどが、直接には分からない原因に当たります。

生成モデルは「感覚が生じる仕組み」を表す

生成モデルとは、世界や身体がある状態なら、どのような感覚が生じるかを表すモデルです。例えば、人がこの距離に立ち、この方向から光を受けていれば、どんな輪郭が見えるでしょうか。看板なら、どう違うでしょうか。

モデルが表すのは、原因から感覚が生じる関係です。知覚では、そのモデルを使い、実際に得られた感覚から、逆向きに原因を推定します。数学的には、原因と感覚の関係を確率で表します。同じ対象でも、照明や距離によって見え方が変わるため、一つの感覚に一つの原因が必ず対応するとは考えません。

人がよく立つ場所だという経験は、そこに人がいるかもしれないという見込みを支えます。こうした経験や状況に基づく、観測前の見込みを確率で表したものが「事前分布」です。一方、輪郭が動かないことに気づけば、その観測を手がかりに見込みを修正できます。観測を踏まえて更新した見込みを表すのが「事後分布」です。もともとの見込みと得られた証拠を組み合わせて更新する考え方が、ベイズ推論です。

ここでの「生成」は、感覚が生じる過程を表すという意味です。画像や文章を作る生成AIと数理的な考え方が重なる場合はありますが、生成モデルという言葉の用途はそれより広いものです。また、頭の中に精密な映像を映して、それを誰かが眺めている、と想定する必要もありません。

予測と感覚を照らし合わせて理解を更新する

人だと推測すれば、姿勢が変わる、服の輪郭が見える、といった感覚が予測されます。実際の見え方と照らし合わせ、説明しきれないずれがあれば、推定を修正します。近くに店の入口があると気づき、看板の可能性を高く見積もることもあるでしょう。

この更新の仕組みを説明する有力なモデルが「予測符号化」です。階層的なモデルでは、対象や場面を表す上位の層から下位の層へ予測を送り、その予測と合わない情報を上へ返して、推定を更新すると考えます。自由エネルギー原理が知覚や行動を共通の数理で捉えるのに対し、予測符号化は、推定をどのような情報のやり取りで実現するかを説明します。

ここでの「予測」は、未来の先読みだけでなく、現在の感覚がどう生じたはずかを見積もることも含みます。予測符号化は、いま目の前にあるものの知覚にも関わる説明です。

その際、ずれの大きさだけでなく、情報の確かさも関わります。暗い場所で見えた曖昧な輪郭と、明るい場所で見えた鮮明な輪郭は、同じ重さの証拠にはなりません。この重みづけに関わるのが「精度」です。モデルでは不確かさの小ささを表し、例えば分散の逆数として扱います。

いまの推定と、経験からの学習

目の前の影を人か看板かと判断するのは、現在の状態についての「推論」です。一方、何度も同じ道を通り、この店の前には人型の看板があると覚えることは、次の推論を支える「学習」に当たります。推論では、今の状態の見積もりを更新します。学習では、感覚と原因の関係など、モデルを形づくる知識を更新します。

ただ、遠くから眺めているだけでは、どちらか決められないこともあります。そのとき私たちは、考え直すことに加えて、近づいて確かめられます。

第3章　行動して確かめる――能動的推論

近づくことで、知るための条件を変える

数歩進めば、輪郭がはっきりし、横へ動けば、平たい看板なのか、奥行きのある身体なのかを見分けやすくなるかもしれません。行動すると、得られる感覚の条件そのものが変わります。

感覚に基づく推定の更新と、行動による環境への働きかけを結びつける枠組みが「能動的推論」です。推論を済ませてから動くという一方向の流れではなく、推定が行動の選択を導き、行動で得た感覚が次の推定を変える循環として捉えます。

目標に近づく行動と、情報を得る行動

ここで、あなたは友人と待ち合わせているとしましょう。遠くの影が友人なら、そこへ向かえば会えます。しかし看板なら、歩いても待ち合わせは進みません。目的地へ急ぐ前に、見通しのよい位置へ少し移るほうが役立つ場合があります。

行動の価値には、こうした二つの面があります。会いたい人に会うなど、望ましい結果に近づくことには「実利的価値」があります。人か看板かを見分け、状態についての不確かさを減らすことには「認識的価値」、つまり知ることの価値があります。

一つの行動が、両方の価値をもつこともあります。影へ近づく行動は、正体を確かめると同時に、相手が友人なら合流にもつながります。情報を得るための行動は、目標から外れた寄り道とは限らないのです。

逆に、情報が増えそうな行動なら何でも選ぶ、ということでもありません。見やすい場所までの移動に時間がかかれば、合流が遅れるかもしれません。何を確かめられるかを、行動がもたらすほかの結果と一緒に考えます。

未来の結果を比較する、期待自由エネルギー

では、近づく、横へ動く、その場で待つという選択肢を、どう比べるのでしょうか。能動的推論では、これから取る一連の行動を「方策」と呼び、各方策のもとで何が起こり、何を知れそうかを予測します。その比較に使う量が「期待自由エネルギー」です。

代表的な定式化では、望ましい結果を「事前選好」と呼ぶ分布で表します。目標へ近づける見込みと、得られそうな情報を併せて評価し、期待自由エネルギーを低くする方策を選びます。

「友人に会いたい」という選好は望ましい結果を、「あの影は友人だろう」という推測は実際に起こりそうな結果を表します。また、ここでの「期待」は、願望ではなく、起こりうる結果をその確率で重みづけして評価するという数学的な意味です。

期待自由エネルギーと変分自由エネルギーは、役割が異なります。変分自由エネルギーは、主に、すでに得た感覚に基づいて原因の推定などを更新する際に使います。期待自由エネルギーは、まだ得ていない感覚を見込み、将来の行動方針を比べる際に使います。

ただし、この仕組みだけで最善の行動が保証されるわけではありません。何を推定の対象とし、どの結果を好ましいとし、どの行動を選択肢に入れるかで、選び方は変わります。ロボットに応用するときも、環境についてのモデルや選好の設定が必要です。

知覚し、学び、先を見通して動く。ここまで見てきた働きは、日常で私たちが「心」と呼ぶものと重なります。では、身体と環境を行き来するこの循環から、心をどのように捉えられるでしょうか。

第4章　予測・身体・環境から「心」を捉える

心には、意識されない働きも含まれる

心という言葉から、頭の中の独り言や、喜びや悲しみを思い浮かべるかもしれません。本稿では、それらに加え、ものを見分ける、注意を向ける、経験から学ぶといった、意識されない働きも含めて考えます。

自由エネルギー原理と能動的推論に基づく一つの見方では、心の働きを、身体をもつ私たちが世界や身体の状態を推測し、行動する過程として捉えます。知覚や注意、学習を、身体と環境との関わりの中で結びつけて考える見方であり、心の本質を確定する定義ではありません。

知覚・注意・学習・意思決定をつなぐ

暑い日に駅から待ち合わせ場所へ歩いている場面を考えましょう。日なたの近道を進んでいましたが、暑さが気になり、少し遠回りになる日陰の道へ入ります。

周囲の明るさや身体の感覚から状況を捉え、日陰や休めそうな場所へ注意を向ける。到着までの時間と身体への負担を見込み、進む道を選ぶ。日陰へ入っても暑ければ、さらに休める場所を探す。状況の理解と行動は、その都度、互いを変えていきます。

その経験から、次に同じ道を歩くときの見込みも変わるでしょう。「こちらの道なら涼しく歩けそうだ」という学習が、その場で何を見るか、どの道を選ぶかを支えます。知覚・注意・学習・意思決定は、この場面では、歩き続けるための調整として関わり合っています。

身体の状態が、世界の見え方を変える

同じ道でも、涼しい日に元気に歩くときと、暑さで疲れているときでは、目に留まるものや選びたい経路が違うかもしれません。日陰は、単に暗い場所ではなく、身体を休められそうな場所になります。世界を捉える際には、対象の形や位置だけでなく、自分にとって何ができ、何が必要かも関わるのです。

この見方では、身体の状態は、何に注意を向け、どんな結果を望み、どう動くかを考える条件に含まれます。脳内の推定に加え、実際に日陰へ移り、そこで身体の状態がどう変わり、

何を感じるかまで含めて考えます。その感覚が、さらに休める場所を探すかどうかの判断につながります。

身体や環境が心に関わることと、それらを心そのものに含めることは別の主張です。その境界をどう引くかは、なお哲学的な問いとして残ります。

心の機能と、体験が生じる理由の違い

日陰を探す行動や、注意の向け方をモデルで説明することと、暑さがなぜ「このように感じられる」のかを説明することは、異なる課題です。知覚や意思決定のモデルがあるというだけで、主観的な体験が生じる理由まで分かったとは言えません。

人に話しかけると、相手もこちらの言葉を解釈し、応答します。返ってきた言葉を手がかりに、こちらも相手への理解を変えます。

第5章　同じ考えでなくても、わかり合えるか——対話と共有理解

相手の意図は、直接のぞけない

冒頭の仕事の相談は、説明のための仮想例です。「仕事がうまくいかなくて」と話す友人に解決策を提案したところ、返事が途切れてしまいました。この沈黙から何が分かるでしょうか。

話を聞いてほしかったのかもしれません。しかし、提案を考えている、言いにくい事情がある、疲れて言葉が出ない、といった可能性もあります。自分には筋の通る解釈でも、それが相手の意図に合っているとは限らないのです。

フリストンとフリスは、こうした意図の解釈を、能動的推論から考えています。相手の心を直接確認できなくても、言葉や行動を手がかりに意図を推測し、次の応答からその推測を見直すことはできます。

聞く・話す・問い返すという循環

「すぐに案を出したけれど、今は話を聞いたほうがいい？」と尋ねてみます。友人が「まず何があったか聞いてほしい」と答えたら、聞く側は提案を控え、出来事を話せるように応じられます。「案は助かるけれど、その方法はもう試した」と返ってくれば、必要なのは別の提案かもしれません。

問い返すことは、自分の理解を言葉にして確かめる行動です。こちらの発言が、次に相手から得られる情報を変え、その応答がこちらの理解を変えます。この点で、対話にも、推測と行動が循環する構造を見いだせます。

「つまり、結果よりも、頑張ったことを認めてもらえなかったのがつらいのかな」と言い換えると、「そこまでではないけれど」と訂正されるかもしれません。訂正は、推測が外れた印であると同時に、理解を具体的に変える手がかりになります。相手が否定しやすい余地を残すことにも、意味があります。

しかも、質問は情報を取り出すだけの操作ではありません。尋ね方によって、相手が話しやすくなる場合も、詰められていると感じる場合も考えられます。相手は、こちらの応答を受けて、自分が何を伝えたかったのかを言葉にし直すこともあるでしょう。対話の目的を、不確かさを減らすことだけで尽くすことはできません。

その場での理解と、相手についての学習

いまの沈黙は何を意味するのか。その場の状態を推定することと、やり取りを重ねて、相手の表現や関心について学ぶことは分けられます。原論文では、変化する状態についての推論と、生成モデルのパラメータの学習を、異なる時間スケールの過程として扱います。

相談例に引き寄せれば、何度か話すうちに「この人は事情を整理してから案を考えたいことが多い」と学ぶことが、次の応答を支えるかもしれません。ただし、それは「いつも助言を求めない人だ」と決めつけることとは違います。今日はすぐ案がほしいと言われたら、その場の応答に照らして見込みを変えられます。

その場の解釈は、これまでの学習に支えられます。同時に、今までと違う応答があれば、相手についての理解を学び直す機会になります。対話を重ねれば、相手の応答を予測しやすくなることも、できあがった人物像を修正することもあります。

二羽の鳥のモデルは、何を示すのか

推論と学習の関係を調べるため、フリストンらは、コンピュータ上の二羽の鳥が歌をやり取りするモデルを使いました。ゆっくり変化する上位の状態が、速く変化する下位の状態に影響します。下位の状態は、音の高さや大きさを変えます。それぞれの鳥は、聞こえた歌から、それを生む状態を推定します。

まず、同じ生成モデルをもち、内部の推定（期待値）の初期値が異なる二羽を用意しました。歌う側と聞く側が交代する条件は、感覚情報の重みづけを切り替える形で設定されています。互いの声が聞こえると、聞く側の推定が相手の歌に沿うように変化し、内部状態の時間的な変化がそろいました。歌の交代も、相手が残した流れを引き継ぐものになりました。

これは、二羽がずっと同じ音を繰り返すことではありません。音を生み出す状態の変化が対応し、相手の続き方を予測できる関係です。論文は、二つの系の状態が一定の関係をもって変化する「一般化同期」を論じ、その特殊な場合である、対応する状態が一致する同期を示しています。

次に、上位の状態が下位に与える影響を決めるパラメータを、一方は0.5、他方は1に設定し、歌の変化の豊かさに違いをつけました。やり取りの後にそのパラメータを更新すると、両者の値が近づき、状態の同期も生じました。変化する歌を推定するだけでなく、その歌の生じ方を学ぶことが、この設定のシミュレーションでは、相互予測を支えました。

ただし、二羽は最初から共通のモデル構造を与えられ、その中の特定のパラメータが異なっています。無関係な知識体系や言語をもつ者同士が、必ず理解し合えることを示したわけではありません。著者らも、このモデルには、やり取りする音の意味や文法を与えていないと明記しています。

このシミュレーションは、感覚を介した相互予測と学習から、協調した変化が生じうることを示します。人間の対話を考えるには、それに加えて、何について理解が調整されたのかを問う必要があります。状態が同期することと、発言の意味を理解することは、別のことです。

理解すること、同意すること、協力すること

友人の話を聞き、「評価のされ方に納得できないのだ」と理解しても、その評価が不当だったかについては意見が違うかもしれません。それでも、状況を整理するために一緒にメモを作ることはできます。

この例では、相手が何を問題にしているかを捉えることが理解、その判断を支持することが同意、共同で何かを進めることが協力です。三つを区別すれば、違いを残したまま何を共有できるかが見えてきます。相談のすべての背景に通じていなくても、「まず事情を書き出す」という作業の進め方は共有できます。

ここでいう共有理解とは、対話に必要な意図や言葉の使い方、進め方を、互いの応答から調整できていることです。何が通じ、どこが食い違うかを確かめる余地を含む理解です。モデルの収束や状態の同期と、そのまま同じ意味ではありません。

直接話し合える相手なら、応答から意図を確かめられます。では、互いを知らずに同じ場を使う人々は、どう行動を合わせるのでしょうか。そこでは、一人ひとりへの問い返しに代わり、共有された環境が判断を支えます。

第6章　知らない人同士は、なぜ同じ列に並べるのか——社会秩序

表示や人の並びが、次の行動を導く

初めて使う駅のホームで、床に色の違う線が引かれ、人々が二列に並んでいます。行先表示を確かめ、列が向かう乗降口を見て、最後尾に立つ。並ぶ人の名前も考えも知らないまま、乗車を待つ活動に加われます。

ここで頼りにしているのは、床の線だけではありません。列の向き、人々が空けている通路、先頭の人が待つ位置などが、組み合わさって判断を支えています。「この線は乗車位置を示すのだろう」という解釈も、表示のある場で過ごしてきた経験に支えられます。

この例では、先に来た人が先に乗りそうだという予測と、後から来た自分には最後尾に並ぶことが求められるという期待が重なっています。何が起こるかに加え、この場ではどう振る舞うものなのかが、行動を導いています。

デオンティック・キューという学習された手がかり

その場で期待される行動を示す、学習された手がかりを「デオンティック・キュー」と呼びます。コンスタントらは、これを含む考え方を数理モデルとして定式化しています。明文化された命令に限らず、他者の動きや配置も手がかりになり得ます。

目立つものが何でも、この手がかりになるわけではありません。同じ床の線でも、工事の範囲を示す線なら、そこに並ぶとは限りません。どの状況で、どの行動につながるかという対応が、経験を通じて身につく必要があります。

論文は、観測した手がかりから行動方針を直接導く対応を、デオンティック価値として定式化しています。慣れた表示を見て並べるなら、一人ひとりの意図や、乗車までの展開を毎回詳しく考える負担が減ります。「推論を環境に外部化する」とは、このように環境を判断の支えにできるという意味です。個人の推論がなくなったり、床の表示が代わりに考えたりするわけではありません。

ただし、運行が変わって別の列ができていれば、慣れた対応では判断できません。表示と人の動きの食い違いに気づき、案内を調べたり尋ねたりすることも必要です。学んだ手がかりは、どんな状況でも正しい答えを保証するものではありません。

環境に従う行動が、環境を変える

あなたが最後尾に立つと、次に来る人には、あなたも列の一部として見えます。列の長さや伸びる方向を知る材料が一人分増えました。列を見て並ぶ行動が、次に来る人の判断材料にもなるのです。

この循環を論文は、場所ごとに色などの観測が得られる格子状の環境で定式化しています。個体は得た観測から位置などを推定し、望ましい観測を得たり、不確かさを減らしたりするように移動します。一方、このモデルには、個体がその場所に働きかけると、そこで各観測が生じる確率を更新する規則を組み込めます。

例えば、訪れるたびに好ましい色が生じる割合を高める更新なら、その場所は、個体が選びやすい手がかりを安定して返す方向へ変わります。繰り返しの作用を蓄積した環境は、一度の働きかけでは変わりにくくなるように表せます。手がかりの形成と、その手がかりに沿う行動を、相互に関わる過程として記述する提案です。駅の利用者の行動を測定して得た結果ではありません。

人々が活動を通じて、その後の活動を支える環境を変える。この関係を考える言葉が「ニッチ構築」です。論文は、こうした環境の改変と、社会的な手がかりの形成を結びつけています。

駅では、一時的な列と、長く残る表示を区別する必要があります。列車が出れば列は消えますが、床の線は翌日も残ります。混雑を受けて駅の運営側が整列位置を描き直すなら、利用者の行動が、担当者の判断や工事を介して環境の変更につながります。繰り返し並ぶだけで、床に案内が描かれるのではありません。

人が入れ替わっても続く慣習

翌朝、別の人々が同じ場所を使います。昨日の利用者を知らなくても、残された表示や先行する人の行動を見て並べます。その並び方が、さらに後続の人の手がかりになります。

その場で立つ位置を決めることと、利用を重ねて並び方を覚えることでは、かかる時間が違います。さらに長い期間には、表示や案内方法が維持・修正され、利用者や担当者が交代し

ても引き継がれます。コンスタントらは、活動の痕跡を残す環境が、次の世代の注意や行動の学習を支える可能性を論じています。

この見方では、慣習を受け継ぐことは、頭の中のルールを言葉で伝えることだけではありません。見て学べる行動や、特定の動きを取りやすい場所も、継承を支えます。設備の維持や案内の更新を担う人や組織も、この継承を支えています。

秩序を保つことと、見直すこと

同じ列に並ぶ理由は、人によって違い得ます。順番を守るのが公平だと思う人も、衝突を避けたい人も、不満はあるが従う人もいるでしょう。共有されているのは、少なくとも「ここで待てば乗車の順番を待つ人として扱われる」という実践上の見込みです。

動きがそろうことから、全員が同意しているとは判断できません。また、表示を使い慣れていない人や、最後尾を見つけにくい人が迷っても、慣習を拒否したとは限りません。長く立てない人にとっては、同じ場所に立ち続ける仕組み自体が負担になります。

本稿では、案内を変える、座って待つ方法を設けるなど、順番を守る目的と具体的な手段を分けた見直しを考えます。予測しやすい秩序であることから、公平で望ましい秩序だとは決まりません。誰が手がかりを作り、誰が変更でき、困った人がどこに声を届けられるかも問われます。

表示を理解し、慣習を見直す際にも、私たちは言葉や記号を使います。けれども、表示を頼りに行動を合わせられることと、異なる経験をもつ者同士が共通の呼び名を作れることは、別の問題です。

第7章　共有する言葉はどう生まれるか――集合的予測符号化

それぞれの経験を、共通の記号で結ぶ

同じ容器を前にしても、正面から見る人と、持ち上げて重さや手触りを確かめる人では、得る情報が違います。それぞれが、自分の感覚や経験から対象を捉えています。それでも共通の呼び名を使えれば、互いの経験に関わるやり取りを始められます。

呼び名と対象の対応を最初から知っていると仮定しても、その対応がどう生まれたかは説明できません。個々の経験からの学習と、言葉や記号の形成を結びつけようとするのが、谷口忠大氏の「集合的予測符号化（CPC：Collective Predictive Coding）」です。

個人が身体を通じて得た情報を、記号のやり取りによって結びつける。その結果、集団として経験を捉え、予測する表現が形成されるのではないか。各自の経験から呼び名が形づくられ、その呼び名が各自の学習にも関わるという仮説です。

呼び名を提案し、受け入れる――名付けゲーム

その仕組みを考える例が、メトロポリス・ヘイスティングス名付けゲーム（MH名付けゲーム）です。二つの主体が同じ対象に注意を向け、それぞれ異なる観測と内部のモデルをもつ状況を考えます。対象を捉えるための内部表現や、呼び名との対応は学習の対象ですが、相手の内部変数を直接読むことはできません。

一方が、自分のモデルに基づいて対象の呼び名を提案します。例えば「ネマ」という仮の音だとしましょう。相手は、その名前が自分の観測や学んだ対応にどれほど合うかを用いて、確率的に受け入れるかを決めます。受け入れた名前は学習に使い、受け入れなければその提案は採用しません。話す役と聞く役を交代しながら、対象や呼び名についての推定を更新します。

やり取りするのは名前の候補で、相手が見た画像や内部の確率分布全体ではありません。ただし、同じ対象に注意を向ける「共同注意」と、名前をやり取りできる共通基盤は、この例の前提です。

受け入れる確率は、単なる好みや賛成の度合いではありません。メトロポリス・ヘイスティングス法は、候補の提案と受容・棄却を繰り返し、目的とする確率分布から値を取り出すための計算方法です。その値を「標本」と呼び、この名付けゲームでは名前の候補に当たります。適切な提案・受容の規則のもとで、このやり取りは、二者の観測を踏まえた名前の事後分布を推定する計算に対応づけられます。各自の観測を直接共有せず、分散して推定する仕組みです。

聞く側は、自分の内部表現に照らして、提案された名前と現在採用している名前を比較し、確率的に切り替えます。そのため、いつも同じ候補を選ぶとは限りません。ここで扱うのは、離散的な名前の候補についての推論であり、文法をもつ言語全体の形成と同じではありません。

この手続きでは、多数決や配布済みの辞書に頼らず、各自の観測とモデルを提案・受容に反映させます。中央で全員の内部情報を集めなくても、そのやり取りが集団での推論を構成するのです。

ただし、事後分布を推定することは、一定回数の会話で一つの名前に必ず決まることではありません。候補が複数残ることも含む確率的な計算であり、その性質はモデルの構造と更新規則に依存します。人間が実際にこの規則で名前を決めているかは、さらに検証する問いです。

個人の学習と、社会の記号体系の変化

生成モデルの側から見ると、共有する記号、各自の内部表現、各自の観測が結びついています。記号は、個人の内部表現を介して、どのような観測が生じるかの予測に関わります。推論では逆に、各自の観測を手がかりに、内部表現と共有する記号を見直します。

この関係によって、言葉は、できあがった考えに後から貼る札だけではなくなります。受け入れた記号を使う学習が、個人の対象の捉え方にも影響するからです。一方、個人が得た経験は、どの記号を提案し、受け入れるかに反映されます。記号が個人を支え、個人の活動が記号の共有を形づくる循環です。

例えば、容器の形を見て名付ける側と、手触りを確かめて受け入れる側では、同じ呼び名が結びつく感覚は異なります。各自は、自分が得られる情報と呼び名の対応を学びます。記号が共有されても、感覚や内部表現まで一致するとは限りません。

日常の言葉も、人々が使いながら意味や使い方を変えていくものとして考えられます。しかし、その長い変化には、歴史、組織、教育、立場の違いなども関わります。限られた対象への名付けから、文化全体の変化を説明できたとは言えません。CPCは、個人と記号体系の関係を検討するための仮説として、この先を問い直します。

「社会が予測する」とは、何を意味するのか

ここでいう社会の予測は、社会が一つの意識をもち、頭の中で未来を思い描くことではありません。個々の観測と内部表現を、共有する記号を介して結んだモデルとして、集団の活動を捉えることです。

谷口氏は、複数の主体の観測を結ぶモデルを、変分推論の観点からも捉え、社会全体での自由エネルギー最小化との接続を論じています。ただし、名付けゲームの標本を得る計算と、変分自由エネルギーを最小化する計算は、そのまま同じ手順ではありません。2024年の論文では、その接続を今後の議論にとって意味のある可能性として述べています。

ここでも、数理的に扱える名付けのモデルと、「人間の言語は集合的予測符号化を通じて形成される」という仮説は分けられます。論文も、この仮説を支持する実証的な証拠は十分ではなく、予測を人間のデータと比較して検証する必要があるとしています。

社会秩序の議論では、共有する手がかりが行動を導き、行動がその環境を変える循環を見ました。CPCは、共有する記号と個々の経験が互いを支える循環を扱います。両者は同じ理論ではありませんが、個人の学習を他者や環境との関係に位置づけるという点で、並べて考えられます。

行動して情報を得ることと、相手とのやり取りから記号を調整すること。この二つをAIやロボットに実装するには、観測できる情報や人が準備する条件を定め、何を指標に確かめるかを具体化する必要があります。

第8章　確かめ、学び、意味を共有するAI・ロボット

身体の推定と行動を結ぶ――iCub

人型ロボットiCubが、目の前の対象へ手を伸ばします。Oliver氏らの研究では、カメラが捉えた手先の位置と、関節の角度を測るセンサーの値を使い、身体の状態の推定と運動を結びつけました。身体のモデルからの予測と観測のずれを使って、関節角度の見積もりと、関節を動かす速度を更新します。

実験では、目標位置への到達を調べ、視覚だけ、関節センサーだけ、両方を使う条件を比べました。両方を使う条件は、身体のモデルと実機の食い違いを視覚で補い、用意された目標位置へ到達しました。

別の比較では、目標からの位置誤差を指標とし、従来の逆運動学による制御より小さい誤差を示しました。誤差の基準は、ステレオ視で再構成した手先位置です。逆運動学側は位置制御で動かしています。

ただし、これらは目印で手先を識別できる環境での結果です。身体の推定と制御を検証する実験であり、人間と同じ身体所有感を実現したことを示すものではありません。

中が分からなければ、ふたを開ける——実機の能動的推論

Fujii氏とMurata氏は、見えていないものを調べる行動を、実機ロボットで扱いました。卓上には赤と青の球、皿、鍋などが置かれています。鍋のふたが閉まっていれば、中に赤い球があるかは画像だけでは確かめられません。一方、見えている青い球を皿へ移す行動も選べます。

このロボットは、画像と関節の位置から、環境がどう変わるかを表す「世界モデル」を学びます。ゆっくり変わる状態と速く変わる状態を分け、動作の細かな変化と、まとまった変化を扱います。「行動モデル」は、連続する関節の動きを、ひとまとまりの「抽象行動」に圧縮します。細かな関節指令を一つずつ比較する代わりに、ふたを開けるような一連の運動を、まとまった候補として選べるようにします。「抽象世界モデル」は、その候補を実行した後の、ゆっくり変わる状態を予測します。

学習用の動作は、人がロボットを遠隔操作して収集しました。実験者が用意した8種類の操作パターンをもとに学び、実行時には学習された候補から、期待自由エネルギーが低いものを選びます。目標は画像で与えられます。何を目指すかも、どんな行動ができるかも、準備なしに生まれたわけではありません。

物体操作の評価では、球の移動とふたの開閉を合わせた164試行について、規定時間内の成功率を比較しました。比較対象は、目標画像を用いる拡散方策です。この実装では、直近の二つの観測と目標画像をもとに、これから取る一連の行動を予測します。成功率は、提案手法が70.7％、比較対象が24.4％でした。階層構造や抽象世界モデルを除く条件とも比べ、設計の効果を調べています。ただし、個々の課題のすべてで提案手法が最高だったわけではありません。

探索の実験では、青い球を移す行動と、ふたを開ける行動を比べました。実験者が目標画像への選好の重みを変えると、目標へ向かう行動から、中の状態について情報を得る行動へ選択が変わりました。探索を行動の価値として評価できる例です。ただし、切り替えの設定は手動です。探索を挟むことで最終的な課題の成功率が上がるかは、この実験では評価されていません。

また、学習データにない行動と環境の組み合わせでは、予測の精度が下がります。想像した結果と実際が食い違うと、選択も失敗し得ます。行動の選び方と、それを支えるモデルの確かさは、併せて検証する必要があります。

人とAIが、異なる情報から呼び名を共有する

行動で情報を増やす研究に対し、Okumura氏らの研究は、相手だけが得ている情報を、記号のやり取りで生かす課題を扱います。オンライン実験の分析対象は69人で、相手は確率的な分類モデルを使うAIです。

対象は、切り込みのある円の画像です。人には明るさ・切り込みの角度・大きさが分かる灰色の画像を見せ、AIには色と明るさの数値を与えます。人には色が分からず、AIには形の情

報がありません。

二者は、10個の対象を最大3つのグループに分類し、A・B・Cという呼び名を提案します。この記号自体は実験者が用意しますが、どの対象にどの記号を使うかは、やり取りで変わります。相手の提案を受け入れるかを判断しながら、計200回やり取りします。渡すのは呼び名で、相手の観測や内部のモデル全体ではありません。AIは自分のモデルで分類や記号を推定し、人も画面上で分類を変更できます。正解の分類は評価用に設けられていますが、二者には教えません。

比較したのは、AIがMHの規則で提案を受け入れる条件、必ず受け入れる条件、必ず拒否する条件です。後の二つは、受容の仕方の両極端を比べる対照条件です。

分類には、正解との一致を偶然の一致も考慮して測る調整ランド指数を用いました。AIの内部の分類については、条件間の有意差が認められていません。

呼び名については別の評価も行いました。両者の観測をまとめて推定した記号の分布と、やり取りで得た分布の対応を調べています。MHの受容規則を使う条件では、AIの記号の分布は、常に拒否する条件より、両者の観測を踏まえた分布との対応が有意に高くなりました。一方、常に受け入れる条件との差は、多重比較の補正後には有意ではありませんでした。MH条件が、常に受け入れる条件より優れていたとは、この比較からは言えません。

著者らが「共創的な学習」と呼ぶ中心は、一方が正解を教えるのではなく、相補的な観測を生かす記号体系をやり取りから作ることにあります。各自の内部表現が同じになった、という結果ではありません。用意された対象と呼び名による課題なので、自由な会話で意図や価値観を理解できたこととも区別が必要です。

ロボットの観測から、記号の共有へ

では、生活空間でロボットが実際に見た画像を使うと、どうなるでしょうか。出原健太郎氏、吉田尚人氏、谷口忠大氏は、二台の移動ロボットKachakaを使う実装を報告しています。人がそれぞれを対象の前まで手動で移動させ、同じ対象を見たカメラ画像の対を集めました。何を一緒に見るかは、この段階で用意されています。

画像から対象部分を切り出し、大きさを整えた後、ロボットごとのデータで、それぞれ独立に画像の特徴を学習します。その特徴を内部表現として、MH名付けゲームを行います。実機が撮った画像を扱うことと、移動や共同注意まで自律化することを分けた構成です。

論文は、自然画像で事前に学習したモデルの特徴を使う条件との比較を設け、調整ランド指数や、二者の一致を測るカッパ係数で評価するとしています。ただし、提供された大会論文には、詳細な実験条件と結果は口頭発表で報告すると記されています。この資料から確認できるのは、実世界の観測画像を使う実装手順と評価計画です。数値結果や優劣は確認できません。空間探索や共同注意をロボット自身に担わせることも、今後の展望です。

実験の成功と、日常環境への応用の間

これらの研究は、すべて同じ方法を使っているわけではありません。身体の推定と制御、行動による情報獲得、相手の観測を生かす記号形成を、それぞれ異なる仕組みで具体化してい

ます。

日常で使うための検証も、課題に応じて変わります。ふたを開けるロボットなら、未知の配置でも探索が作業の成功につながるか。名付けの仕組みなら、対象を一緒に見ていることが曖昧な場合や、見分けたい特徴が違う場合にも調整できるか。実験者が与えた目標を達成できることに加え、利用者と目標を確かめ直せるかも問われます。

成功率や記号の一致だけでは、人が納得できる協働かは決まりません。何を優先し、どの失敗を避けたいかには、利害や価値観も関わります。その能力を誰との、どのような関係で使うのかも、協働を考える際の課題になります。

結び　違いを生かし、人とAIが共に学ぶ社会へ

心・対話・社会をつなぐ、相互作用の見取り図

身体の状態や周囲の手がかりによって、注意や行動は変わります。他者に応じれば、返ってくる言葉がこちらの理解を変えます。本稿では、こうした理解と行動の結びつきを、モデルと実験に照らしてたどってきました。ただし、自由エネルギー原理だけから、心や社会のすべてを説明し終えたわけではありません。

AIの回答を読んで、質問を変えたり、判断を見直したりすることもあるでしょう。回答が正しいかに加え、そのやり取りで人の理解や判断がどう変わるかも確かめる必要があります。AIの側が更新される仕組みでも、人の側だけが適応する使い方でも、この点は変わりません。

共生的AIアライメントという問い

アライメントとは、人の意図や価値、目的と、AIの振る舞いの関係を調整する課題です。JST-CRDSの報告書に収められた谷口氏の講演は、「共生的なAIアライメント」が考えられないか、と問いかけます。人の思考もAIから影響を受ける点に目を向け、相互に変化する関係を社会にとって望ましい方向へどう育てるかを探る構想です。完成した一つのアルゴリズムを指してはいません。

目的を調整することは、価値観を一つにそろえることではありません。同じ分類を使えても、何を大切にするかは違い得ます。異なる考えを理解すること、賛成すること、共同作業を進めることの違いは、人とAIの関係でも保つ必要があります。

互いの理解が変わることと、その変化が望ましいことは別です。工藤氏は同報告書の講演で、AIに埋め込まれた偏りが人の判断に影響し、AIと社会の両方で偏りがさらに固定化されるのではないか、と懸念しています。

この懸念を踏まえ、本稿では、人とAIのやり取りで何が変わったかを点検し、修正できる仕組みも必要だと考えます。

信頼・責任・多様性と、人が判断する余地

同じ講演で、工藤氏は、頼ってよいと感じる「信頼」と、計測や観測による裏付けをもつ「信頼相当性」を区別しています。また、開発者、保守者、運用者などの関係と責任分担を

見えるようにすること、決定の理由を振り返り、修正できる過程を論じています。

これを日常の協働に引き寄せるなら、AIが仕事の進め方を提案したとき、誰がどの資料を確かめて採用するのか、採用しなかった案や反対理由を残せるか、といった設計が考えられます。実行前に、どこまで人が判断するかを決めておきます。誤りが見つかったときに、誰が確認し、誰が停止や修正を担うかも明らかにします。

少数の意見が平均的な回答に埋もれず、異議を伝え、決定を見直せること。これらは、本稿が共生の条件として考えたい点です。予測しやすさや合意の速さだけから、公平さは決まりません。何をAIに任せ、人がどの判断を引き受けるかは、関係する人々が検討する問いとして残ります。

冒頭の相談でも、返事が途切れた理由は決めつけられません。「今は一緒に解決策を考えたい？　それとも、まず話を聞こうか」と問い返せます。その答えを受けて、こちらの理解や応じ方を変える。人とAIの協働でも、最初の推測は外れ得ます。人が確かめ、言い直し、自分で判断し直せる余地を残したいのです。

参考文献

Constant, A., Ramstead, M. J. D., Veissière, S. P. L., & Friston, K. (2019). Regimes of expectations: An active inference model of social conformity and human decision making. *Frontiers in Psychology, 10*, Article 679. https://doi.org/10.3389/fpsyg.2019.00679

Friston, K. J., & Frith, C. D. (2015). Active inference, communication and hermeneutics. *Cortex, 68*, 129–143. https://doi.org/10.1016/j.cortex.2015.03.025

Friston, K. J., Shiner, T., FitzGerald, T., Galea, J. M., Adams, R., Brown, H., Dolan, R. J., Moran, R., Stephan, K. E., & Bestmann, S. (2012). Dopamine, affordance and active inference. *PLOS Computational Biology, 8*(1), Article e1002327. https://doi.org/10.1371/journal.pcbi.1002327

Fujii, K., & Murata, S. (2025). *Real-world robot control by deep active inference with a temporally hierarchical world model* (Version 1) [Preprint]. arXiv. https://arxiv.org/abs/2512.01924v1

Lanillos, P. (2020, January 27). Is this my body? (Part I). *MSRM Blog*. https://msrmblog.github.io/is-this-my-body-1/

Okumura, R., Taniguchi, T., Taniguchi, A., & Hagiwara, Y. (2026). *Co-creative learning via Metropolis-Hastings interaction between humans and AI* (Version 2) [Preprint]. arXiv. https://arxiv.org/abs/2506.15468v2

Oliver, G., Lanillos, P., & Cheng, G. (2020). *Active inference body perception and action for humanoid robots* (Version 3) [Preprint]. arXiv. https://arxiv.org/abs/1906.03022v3

Taniguchi, T. (2024). Collective predictive coding hypothesis: Symbol emergence as decentralized Bayesian inference. *Frontiers in Robotics and AI, 11*, Article 1353870. https://doi.org/10.3389/frobt.2024.1353870

磯村 拓哉. (2022). 自由エネルギー原理. *脳科学辞典*. https://doi.org/10.14931/bsd.10024

乾 敏郎・阪口 豊. (2020). *脳の大統一理論――自由エネルギー原理とはなにか*. 岩波書店.

科学技術振興機構 研究開発戦略センター. (2025). *俯瞰セミナー＆ワークショップ報告書 人・AI共生社会のための基盤技術* (CRDS-FY2024-WR-08). 科学技術振興機構. https://www.jst.go.jp/crds/report/CRDS-FY2024-WR-08.html

谷口 忠大. (2023). 自由エネルギー原理と記号・言語創発―集合的予測符号化から大規模言語モデルまで―. *人工知能, 38*(6), 810–817. https://doi.org/10.11517/jjsai.38.6_810

出原 健太郎・吉田 尚人・谷口 忠大. (2025). 移動ロボットによる実世界メトロポリス・ヘイスティングス名付けゲーム. *人工知能学会全国大会論文集（第39回）*, 3O4-OS-44b-02. https://doi.org/10.11517/pjsai.JSAI2025.0_3O4OS44b02