解説資料：「自由エネルギー原理から読み解く心・社会・AI」の重要キーワード

本資料は、セッション「自由エネルギー原理から考える社会・心・AI」で取り上げる中核的概念、数理構造、実証エビデンス、社会実装論を整理したセッション用配布資料である。カール・フリストンによる単一生命・脳の適応原理から、身体性ロボティクス、対話における神経ヘルメネウティクス、環境を介した社会秩序の創発、集合的予測符号化（CPC）による言語創発、人間とAIが共創する社会システムのデザインに至るまで、多層なスケールを貫く理論的見取り図を、黒板セッションの形で解説する。各節の見出しに、対応するスライド番号を明記した。

1. セッションの見取り図：多層スケールで連動する適応と推論の階層（スライド1–2）

生命が変化の激しい外部環境の中で自らの生存可能領域（ホメオスタシス）を維持し続ける適応のメカニズムは、頭蓋骨の内部に閉じた情報処理にとどまらない。感覚信号の推論から身体運動、他者との対話、環境を介した秩序形成、そして言語やAIを含む記号体系の共創へと、地続きに連なっている。

本セッションは、日常の一場面から始まる。友人に「仕事がうまくいかなくて悩んでいる」と相談され、良かれと思って「こういう解決策やタスク管理ツールを試したらどう？」と具体的な助言を返した途端、返信が途絶え、気まずい沈黙が流れた。後になって「相手は助言ではなく、ただ愚痴を聞いて共感してほしかったのかもしれない」と気づく。言葉の字面や辞書的な意味は完全に一致しているのに、相手が求めている真の意図や文脈的期待がすれ違ってしまう。**「単なる情報伝達」と「意味の共有」は全くの別物**であり、同じ溝は大規模言語モデル（LLM）と人間の対話にも日々現れている。正しい知識を返すことと相手の文脈に寄り添うことの間には、どのような溝があるのか。直接見えない相手の心を推測し、環境や社会の中で協調行動を成立させるには、どのような計算メカニズムが背後に働いているのか。これが本セッションを貫く問いである。

黒板メモ【本日のセッションの全体見取り図：ミクロからマクロへの展開】

- **第1〜3章：個体・脳・能動的推論（数理的基盤）**
  - ホメオスタシス維持から導かれる変分自由エネルギー（VFE）最小化と、原理・モデル・実装の三層の区別
  - 生成モデルと予測符号化（精度）、推論と学習の時間スケール分離
  - 能動的推論（Active Inference）と期待自由エネルギー（EFE）による探索と搾取の自動平衡
- **第4章：身体性と「心」の動的調整**
  - 固定的実体ではなく「脳⇄身体⇄環境」の動的調整プロセスとしての心
  - 身体状態がアフォーダンスを立ち現れさせる機制と、計算モデル／クオリアの境界
- **第5章：対話と神経ヘルメネウティクス**

    - 直接見えない他者の意図をめぐる双方向の予測誤差修正ループと「問い返し」の計算的役割
    - 二羽の歌鳥モデルが示す一般化同期（同一モデル前提）と「理解・同意・協力」の概念分離（発表者の整理）
- **第6章：環境外部化と社会秩序**
    - 期待のレジーム（ROE）理論とデオンティック・キュー（規範的手がかり）
    - ニッチ構築による計算の環境キャッシュ、慣習の継承、予測可能性と公平性の分離
- **第7章：集合的予測符号化（CPC）と言語創発**
    - 記号創発システム（SES）におけるミクロ・マクロループ
    - メトロポリス・ヘイスティングス名付けゲーム（MHNG）と、その再帰的拡張（RMHNG）
    - 「集合的世界モデル仮説」：LLMの世界理解をめぐる仮説と、その実証課題
- **第8章：実機検証**
    - iCub の到達運動、鍋とボール課題における認識的探索、人とAIの共創学習
    - 生活空間におけるMHNG（Kachaka）：現時点では実験設計の報告にとどまる
- **結び：人・AI共生知能**
    - 多層ループの総括、共生的AIアライメント、信頼相当性と Fail-smart

2. コア理論：自由エネルギー原理と能動的推論の数理（スライド3–11）

外部世界の原因を直接知ることができない生物は、限られた感覚器官からの入力をもとに世界の状態を推測し、生き延びるための行動を選択しなければならない。自由エネルギー原理は、この知覚、学習、行動を単一のコスト関数最小化として定式化する。

変分自由エネルギー（Variational Free Energy: VFE）

カール・フリストンによって提唱された自由エネルギー原理（Free Energy Principle: FEP）の中心をなす情報論的指標である。生物は変化し続ける物理世界の中で、感覚入力を通じて自らの状態を捉え、経験から学び、必要な行動を選択しなければならない。ヒトであれば、体温が42度を超えたり極度の脱水状態に陥れば生存は極めて難しい。この生存可能な範囲（ホメオスタシス）を保ち続けることを、FEPは「変分自由エネルギー F を小さく保ち続けること」として数理的に言い換える。

注意：ここでいう「自由エネルギー」は、身体の燃焼カロリーや気持ちの余裕といった日常語の自由エネルギーとは全く異なる、情報理論的な量である。

変分自由エネルギー F は、ある感覚入力が生起したときの「シャノンサプライズ（負の対数モデル証拠）」に対する数学的な上限（Upper Bound）を与える。サプライズとは、現在の内部モデルのもとでその感覚がどれほど生起しにくいかを表す統計的指標である。しかし真のサプライズを直接計算することは積分計算が難しく、そのままでは扱いにくい。そこで脳は、扱いやすい F を計算してこれを引き下げることで、間接的にサプライズを低減させる。

$$F = \text{複雑さ (Complexity)} - \text{正確さ (Accuracy)}$$

変分自由エネルギーは、数学的には認識確率分布 $q(s)$ と真の事後確率分布 $p(s|o)$ との間のカルバック・ライブラー情報量（KLダイバージェンス）と、感覚信号のシャノンサプライズ $-\ln p(o)$ の和として表される。

- **正確さ（Accuracy）**：観測された感覚データが現在の推定モデルによってどれほど適切に説明されているかを表す尺度である。
- **複雑さ（Complexity）**：新たな観測を受けて更新された推定（事後分布）が、過去の経験に基づく事前の見込み（事前分布）からどれだけ乖離したか（KLダイバージェンス）を表す尺度である。
- **黒板のポイント【オッカムの剃刀】**：変分自由エネルギーの最小化は、観測データを最大限に説明する「正確さ」を高めつつ、事前の信念を無駄に変えすぎない「複雑さ」を抑制する、無駄のない変分ベイズ推論の自律的な実行である。これは「オッカムの剃刀」の数学的体現にほかならない。

原理・モデル・実装の三層構造（FEPの適用範囲）

自由エネルギー原理を議論する際に必ず押さえるべき注意点である。黒板の3段ピラミッドは、次の3層を厳密に区別せよと告げている。

- **上段：自由エネルギー原理（FEP）**：抽象的で普遍的な数理原理。しかし原理単体からは、「生物が何を見て、どのような筋肉やモーターを動かすか」という具体的な振る舞いは一切導かれない。
- **中段：具体的な生成モデル**：環境の構造、身体の入出力、何を推測するかを仮定して初めて、具体的な予測が可能になる。
- **下段：神経回路・実機ロボットの物理実装**：そのモデルが実際の行動や生理データに当てはまるかを、観察や実験によって実証的に検証する層。

黒板のポイント【原理の美しさは個別モデルの正しさを保証しない】：数理的前提が美しいからといって、個別のモデルや神経実装の仮説までが無条件に正しいと証明されたわけではない。原理、個別モデル、実験検証の3層を常に区別して議論する。

生成モデル（Generative Model）

外部世界の特定の原因や身体の状態（隠れ状態 s）が存在するとき、どのような感覚信号 o が観測されるかという確率的因果関係を記述する内部モデルである。結合確率分布 $p(o, s)$ として脳内に表現される。生物の知覚は、この生成モデルに基づいて、生じた感覚信号からその背後にある見えない原因を逆推定（ベイズ推論）する過程として定式化される。

夕暮れの薄暗い帰り道、遠くに人影のような黒いシルエットが見えたとする。誰かが立っているのか、等身大の人型看板なのか、輪郭がぼやけて判別できない。網膜に届いているのは光の強度や明暗の2次元パターン（観測 o）に過ぎず、「そこに友人の田中さんが立っている」という正解ラベルが直接脳に送られるわけではない。脳は「もし世界や身体が状態 s にあるならば、どのような感覚 o が生起するはずか」という生成モデルを内部に持ち、観測から隠れ状態を逆向きに推定する。

予測符号化（Predictive Coding）と精度（Precision）

脳の階層的神経回路における計算モデルである。上位層から下位層へは現在のモデルに基づくトップダウンの「予測信号」が送られ、下位層からは実際の感覚入力と予測との差分であるボトムアップの「予測誤差（Prediction Error）」のみが上位へと返送される。脳神経系において、階層的ベイズ推論をリアルタイムに実行している有力な計算アーキテクチャである。

- **精度（Precision）**：感覚信号や予測誤差の不確かさの逆数（分散の逆数）として定義される信頼度ゲインである。暗闇やノイズ環境における曖昧な感覚信号は精度が低く設定され、予測誤差の重みづけが抑制されることで、既存の事前知識が知覚を支配する。注意（Attention）とは、この予測誤差に対する精度ゲインの能動的な上方修正として理解される。

推論と学習の時間スケール分離

予測符号化のアーキテクチャを理解する上で外せない構造である。

- **推論（Inference）**：目の前の影が人なのか看板なのかを数ミリ秒から数秒の単位で判断し、内部の隠れ状態の推定値（確率分布）を高速に変化させる。
- **学習（Learning）**：より緩やかな時間スケールで進行する。何度も同じ道を通るうちに「この店の前には人型の看板が置いてある」という環境の恒常的な知識を獲得し、生成モデル自体のパラメータや重みを更新する。

高速な状態推論が目の前の環境変化に即応する柔軟性をもたらし、遅いパラメータ学習が環境の安定した構造を記憶として蓄積する。この時間スケールの分離があるからこそ、生物は激動する環境でパニックを起こさず、適応性と安定性を両立できる。

能動的推論（Active Inference）

知覚（内部信念の更新）だけで予測誤差を解消できない場合、生物は自ら運動や行動を生成して環境に直接働きかけ、予測された感覚入力を能動的に獲得しに行く。薄暗い道で影を眺めるだけでは人か看板かを100%見分けられない。だから数歩近づき、横へ回り込んで奥行きを確認する。推論の後に受動的に行動するのではなく、行動そのものが推論の環を閉じる不可分な構成要素とされる。

黒板のスローガン【行動すること自体が推論プロセスの一部】：推論を終えてから動くのではない。行動すること自体が、推論プロセスそのものの一部なのだ。

期待自由エネルギー（Expected Free Energy: EFE）

将来の方策（行動系列 π）を選択する際に評価される目的関数である。未だ観測されていない未来の行動系列において生じ得る感覚を見込み、期待される自由エネルギーを評価する。

$$G(\pi) = \text{期待実利的損失 (Expected Pragmatic Loss)} + \text{期待認識的損失 (Expected Epistemic Loss)}$$

- **実利的価値（Pragmatic Value）**：目標達成や生体維持など、望ましい結果（事前選好 $p(o)$）を実現する価値である。遠くの影が待ち合わせの友人なら、そこへ向かうことは合流という望ましい結果を達成する。
- **認識的価値（Epistemic Value / ベイズサプライズ）**：環境の隠れ状態に関する不確かさを減少させ、新たな情報を獲得する探索の価値である。影が看板なら近づいても会えないが、正体を暴いて不確実性を消し去る価値がある。
- **黒板のポイント【探索と搾取の自動統合】**：不確実性が高い状況では認識的価値（探索）が自然に優位となり、不確実性が解消されるにつれて実利的価値（搾取・目標達成）へと自律的に移行する。強化学習の難問であった「探索と搾取のトレードオフ」が、EFE最小化から自然に導き出される。

VFEとEFEの役割分担

試験に出るくらい重要なポイントである。2つの自由エネルギーは、時間軸と機能がはっきり異なる。

区分	時間軸	対象	役割
変分自由エネルギー（VFE）	過去から現在	すでに身体が受け取った感覚信号	隠れ状態やモデルパラメータを更新し、現在のサプライズを抑え込む（現在を解釈する）
期待自由エネルギー（EFE）	未来	まだ実行しておらず感覚も得ていない将来の方策	実利的損失と認識的不確実性の和を評価し、行動を選択する（未来を選ぶ）

「現在を解釈するVFE」と「未来を選択するEFE」。この2つが相補的に噛み合うことで、生物の適応的な知覚と行動のループが駆動される。

マルコフブランケット（Markov Blanket）

システムにおいて内部状態と外部状態を統計的に分離し、条件付き独立にする境界構造である。マルコフブランケットは、外部から内部へと影響を伝える「感覚状態」と、内部から外部へと影響を及ぼす「能動状態（運動状態）」の2つのサブシステムから構成される。単一細胞の細胞膜から個体の皮膚、さらには脳の各階層構造に至るまで、多重の入れ子状（ネスト）として存在し、系が環境と相互作用しながらも自律的な自己を維持する基礎となる。

アロスタシス（Allostasis）

環境の急激な変化や将来の危機を予測し、ホメオスタシス（恒常性）の破綻を未然に防ぐために、あらかじめ生理的な設定値や事前選好そのものを動的に変更・調整する適応機能である。内受容感覚の事前分布の変更と、それに伴う予測誤差処理の枠組みで説明される。

3. 心と身体：予測・アフォーダンス・神経ヘルメネウティクス（スライド12–17）

知覚や行動の計算論は、身体の物理的制約や環境との関係性、そして他者とのコミュニケーションにおいて質的な飛躍を遂げる。心は頭蓋骨の中に閉じこもった計算器ではなく、世界との動的なネゴシエーションそのものである。

「心」の動的調整プロセス観

自由エネルギー原理において、「心」とは脳内に局在する固定的実体や物質ではなく、身体を持つ主体が生成モデルに基づいて世界や身体の状態、そして将来の展開を推論し、行動を通じて環境との適合関係を動的に調整し続ける連続的なプロセスそのものとして位置づけられる。意識されない無意識の生理的調整や反射的知覚も、広義の心のプロセスに包括される。心とは名詞ではなく動詞であり、生命が自らの存在を維持するために環境と対話し続ける動的な適応関係そのものである。

身体性（Embodiment）とアフォーダンス

喉の渇き、体温、疲労といった身体状態は、単なる知覚入力ではなく、生成モデルの事前分布やEFEの評価軸そのものを構成する。アフォーダンス（環境が主体に提供する行為の可能性）は、主体の身体能力や現在の生理的欲求、物理的制約と環境の幾何構造が切り結ぶ接点において立ち現れる。疲労した身体にとって「日陰」が単なる暗がりではなく「休息の場」という行動候補として強く知覚されるのは、身体状態が生成モデルの方策空間を直接規定しているからである。

夏の暑い日、駅から待ち合わせ場所へ歩く場面を想像されたい。皮膚の温度や日差しの強さから危険を察知する「知覚」。視覚の中で涼しそうな木陰に焦点を当てる「注意（精度の割り当て）」。遠回りでも日陰ルートを進むと決める「意思決定（EFE最小化）」。そして「この道は涼しく歩ける」と記憶を更新する「学習」。これらは別個のモジュールではなく、歩き続けるための単一の適応調整ループである。

計算モデルと主観的体験の境界（クオリア）

ここで黒板中央の点線の壁に立ち止まり、哲学的な境界線を引いておかなければならない。

- **左側：機能的・計算的モデル**：予測誤差を最小化し、EFEを計算して日陰へ移動する行動のアルゴリズムは、FEPによって明快に説明できる。
- **右側：クオリア（意識の主観的体験）**：なぜ私たちは、暑さを単なる計算パラメータとして処理するだけでなく、「うだるように暑い！」という生々しい主観的実感として感じるのか。

黒板のポイント【ハード・プロブレムは解かれていない】：計算モデルのアルゴリズムが完全に解明されたからといって、「なぜ主観的な意識体験が生じるのか」という意識のハード・プロブレムまでが同時に解決されたと錯覚してはならない。計算論的説明の圧倒的な有効性と、主観的現象性の謎の境界を誠実に見据える姿勢を忘れないこと。

神経ヘルメネウティクス（Neural Hermeneutics）

他者の脳内状態や真の意図は、直接観測することができない隠れ状態である。どんなに科学が進歩しても、私たちは他者の神経発火や感情を直接のぞき見ることはできない。観測でき

るのは、相手が口から発する音響信号や言葉、表情、身振りといった感覚データだけである。フリストンとフリスは、対話とは、この隠れ状態を発話や表情を手がかりに予測符号化と能動的推論によって解釈し、互いに更新し合っていく高次の解釈学（ヘルメネウティクス）の循環ループであると定式化した。

問い返しという能動的行動

対話のループにおいて、「問い返し」は驚くべき計算的役割を果たす。「良かれと思って解決策を提案したけれど、今はまずじっくり話を聞いてほしかったのかな？」と言い換えて相手に尋ねてみる。すると相手から「うん、まずは何があったか聞いてほしい」という応答が返ってくる。問い返しという能動的行動をとることで、相手から得られる感覚フィードバックの条件が変わり、自分自身の予測誤差をドラスティックに修正できる。

黒板のポイント【訂正の余白を残す】：相手が否定したり訂正したりしやすい余白を残して発言することこそが、対話における相互推論の精度を一気に引き上げる最高の手がかりになる。さらにこの対話を通じて、その場の文脈理解だけでなく、「この人はまず状況を整理したいタイプだ」という相手の生成モデル自体の長期的学習が並行して進む。

一般化同期（Generalized Synchrony）とその前提

フリストンらは、対話における相互予測の数理的ダイナミクスを、二羽の歌鳥が歌を掛け合うコンピュータシミュレーションによって示した。同じ生成モデルを持つ二羽が交代で聞いたり歌ったりすると、相手の歌から相手の内部状態を能動的推論し、互いの内部状態が一定の関係性を保って同調する「一般化同期」が創発する。脳を直接ケーブルで繋がなくても、感覚のやり取りだけで相互の同期が起きるのである。

- **同一モデル前提という但し書き**：これは「同じ生成モデルを持つ二羽」という前提つきの結果である。人間の対話のようにモデルが異なる場合、同期の成立条件は自明ではない。
- **知覚学習による同調（シミュレーションの範囲）**：二羽の鳥の生成モデルが1つのパラメータだけ違う設定（q=0.5とq=1）で、聞こえた歌への予測誤差にもとづく信念更新を重ねると、二羽のパラメータが近づき、同期が現れた（Friston & Frith, 姉妹論文）。論文はこれを「ヘルメネウティクスの循環が閉じる」と表現している。人間の対話（方言や語彙のずれ）にそのまま当てはまるかは、このシミュレーションからは言えない。

対話における3概念の峻別マトリクス（発表者の整理）

この3区分はFriston & Frithの論文の結果ではなく、発表者が人間社会の対話を考えるために整理したものである。今回確認した範囲では、鳥のシミュレーションに「同意」「協力」を扱った記述は見つからなかった。

概念区分	定義と認知科学的メカニズム	同調・一致の対象	不一致時の状態・帰結
理解 (Understanding)	相手の生成モデル、文脈解釈、前提としている隠れ状態を把	相手の内的状態のモデ	誤解・すれ違い

概念区分	定義と認知科学的メカニズム	同調・一致の対象	不一致時の状態・帰結
	握・推定すること	ル化	
同意 (Agreement)	相手の主張・評価に賛成し、自分も採用すること	信念・主張・評価の一致	意見の相違・反論（理解した上で受容を拒否）
協力 (Cooperation)	共通の目的や社会課題を達成するために、互いに役割を分担して行動系列を実行すること	行動・方策・物理的協調	対立・非協力（ただし同意なき協力は成立可能）

黒板のポイント【同意なき理解と協力】：意見（同意）が食い違っていても、相手の意図を理解し、共に作業を進める協力は両立しうる、というのが発表者の考えである。

4. 環境と社会秩序：期待のレジーム（ROE）とデオンティック・キュー（スライド18–20）

見知らぬ人々が混雑した駅のホームで整然と列を作れるのは、お互いの頭の中をテレパシーで読んでいるからでも、中央集権的な監視者がいるからでもない。並んでいる人同士は互いの名前も仕事も性格も知らず、一語も言葉を交わしていない。駅員がメガホンで一人ひとりに命令しているわけでもない。人間は推論の計算負荷を環境へと巧みに外部化している。

期待のレジーム（Regimes of Expectations: ROE）理論

コンスタントらが提唱した社会的意思決定の枠組みである。社会規範や文化的な行動ルールが、共有された予測構造（期待のレジーム）として個人の能動的推論を方向付ける数理メカニズムを説明する。

デオンティック・キュー（Deontic Cues）とデオンティック価値

その文化社会において「その場でどのような振る舞いが期待されているか」を指し示す、学習された環境の手がかりである（駅のホームの整列線、赤信号、非常口のピクトグラムなど）。

- **デオンティック価値（Deontic Value）**：デオンティック・キューを観測した際、複雑な状況推論や効用計算をバイパスして、特定の行動方針（例：白線の後ろに並ぶ）に対して直接的に割り振られる行動選択価値である。周囲の人の複雑な意図をいちいち推論することなく、環境の手がかりに従うだけで、集団全体が自律的に同調できる。

ニッチ構築（Niche Construction）と環境への推論外部化（キャッシュ）

個体が環境に物理的な改変を加え、その改変された環境が自らや後続世代の適応条件を有利にする生態学的プロセスを指す。人間社会において、看板、区画線、道路標識などのデオンティック・キューを配置することは、脳内で行うべき莫大な「実利的・認識的価値の最適方策計算」を環境側へ「キャッシュ（外部保存）」する行為である。もし駅のホームで毎回

「誰が先に来たのか、どこに立てば公平か」をゼロから計算していたら、脳の計算コストは爆発してしまう。床に引かれた線を見るだけで行動が決まるなら、認知負荷は劇的に削減される。さらに、人々が列に並ぶという行動そのものが、後から来た人に対して「ここが列の最後尾だ」という新たなデオンティック・キューを提供し、環境を改変していく。

ディリクレ分布の集中度パラメータと、環境に埋め込まれた手がかりの頑健さ

Constantらのモデルでは、観測と状態の対応（尤度行列）をディリクレ分布で表す。その集中度パラメータは「経験した事象の数」とみなせ、値が大きいほど、その対応は変わりにくい。複数の主体が同じ手がかりに従って行動し続けると、環境の期待は共同体の共有された選好に近づく。論文は、環境に符号化されたデオンティック・キューが、生態学的・情報的継承を通じて世代を超えて受け渡され、注意や探索のスタイルが再生産されうると述べている。

（踏み固められた道や、同じ場所に並ぶ人々の姿は、説明のための例であり、論文の例ではない。）

社会的同調（Social Conformity）の二面性と制度的公平性

デオンティック・キューに基づく社会的同調は、社会の予測可能性を高めて摩擦を減らす一方で、硬直化した秩序を生み出すリスクを孕む。

- **同調の効用**：他者の意図をいちいち推論する計算負荷を減らし、集団の協調を容易にする。
- **排除とアクセシビリティの課題**：車椅子利用者や体調の悪い人にとっては、同じ場所に立ち続けることを求める秩序が過度な負担となる。予測可能な秩序がそのまま倫理的に公平で正当な秩序を意味するわけではない。
- **黒板のポイント【誰が手がかりを再設計できるか】**：秩序の予測可能性を保ちつつ、誰がその手がかりを変更し、再設計できるのかを問い続ける視点が不可欠である。

5. 言語と記号創発：集合的予測符号化（CPC）と名付けゲーム（スライド21–23）

CPC仮説では、言語を、社会を構成する多数のエージェントが世界を共同で予測するために創発させる、分散的な表現学習の仕組みとして捉える。物理的な床の線よりもはるかに抽象的で強力な共有システムが、言語・記号にほかならない。

記号創発システム（Symbol Emergence System: SES）とミクロ・マクロループ

谷口忠大らが提唱する言語創発のシステム論的記述である。

- **ミクロ層**：各個体が実世界環境との身体的感覚運動相互作用を通じて行う、マルチモーダルな概念・表現学習（ボトムアップの知覚）。

- **マクロ層**：エージェント集団が記号（言葉）のやり取りを通じて自己組織化的に形成する、共有記号・規範体系（トップダウンの社会的拘束）。

このミクロとマクロが互いを制約し、生成し合う循環構造を「ミクロ・マクロループ」と呼ぶ。

集合的予測符号化（Collective Predictive Coding: CPC）仮説

個体の脳内で働く予測符号化を社会全体のスケールへと拡張した仮説である。社会を構成する無数の個人が、記号を媒介として多体観測データを統合し、社会全体としての変分下限（ELBO）を最大化（＝集合的自由エネルギーを最小化）するように分散ベイズ推論を行っていると捉える。CPC仮説は、言語を、社会が世界を予測するために協働構築した分散表現学習の仕組みとして捉える。

メトロポリス・ヘイスティングス名付けゲーム（MHNG）

中央の管理者や配布された辞書が存在しない中で、新しい言葉や概念の共有が始まるための具体的アルゴリズムである。共同注意（Joint Attention）のもとで、2体のエージェント（話者と聞き手）が物体の呼び名を共有していく確率的コミュニケーションゲームである。

1. **知覚**：話者と聞き手が同一の対象物体 d を観測し、それぞれの内部潜在表現 z^{Sp}, z^{Li} を推論する。
2. **発話サンプリング**：話者は自らの内部パラメータに基づき、事後分布から記号 w^{Sp} をサンプリングして発話する（「これを“ネマ”と呼ぼう」）。
3. **MH受容判定**：聞き手は、相手の頭の中を覗くことなく、自らの観測および内部信念に基づき、以下のメトロポリス・ヘイスティングス受容確率 r に従って記号を受け入れるか棄却するかを決定する。

$$r = \min\left(1, \frac{P(z^{Li}|\phi^{Li}, w^{Sp})}{P(z^{Li}|\phi^{Li}, w^{Li})}\right)$$

4. **学習とターンテイク**：全対象についてMH通信を終えたあと、聞き手が自分のパラメータ（θ^{Li}, ϕ^{Li}）を更新する。その後、話者と聞き手の役割を交代して1に戻る。

二者を一つにまとめた確率的生成モデルを考えると、この対話の繰り返しは、そのモデルに対するメトロポリス・ヘイスティングス法（MCMC）と同じものであることが数学的に示されている。これにより、互いの内部状態を見ずに、二者の観測を合わせた事後分布 $P(w|o^{Sp}, o^{Li})$ に向けた分散的な（近似）ベイズ推論が成り立つ。ただし、これはそのモデルの仮定のもとでの理論的な保証である。

再帰的メトロポリス・ヘイスティングス名付けゲーム（RMHNG）

犬飼らによって提案された、$N \geq 3$ のマルチエージェント集団へのMHNG拡張理論である。3体以上のエージェント間において、2者間のMHNGで得られたサンプリング結果を次のエージェントへの提案分布として再帰的に適用することで、集団全体の多体観測 $P(w|o^{1:N})$ からの事後分布サンプリングを可能にした。

- **1サンプル近似（OS）**：厳密なRMHNGは、エージェント数 N に対して計算量が指数関数的に増える。そこで、内部のMCMC反復回数 T を1（$T=1$）にしたものが1サンプル近似で、再帰通信の計算量は $O(N)$ に下がる。
- **有限長近似（LL）**：再帰通信のチェーンを N 体から M 体（$M \leq N$）に切り詰める。データ点ごとにエージェントの順序をシャッフルすることで、全体に情報が統計的に伝わると期待する。
- **結果**：論文の結論は、RMHNGが、Gibbsサンプリングで得た事後分布との一致率で、合成データでは87%超、YCB実画像物体データでは71%超となり、事後分布を近似した、というものである。
    - 本文では、RMHNGの一致率は合成データで0.96、YCBで0.76と書かれている。結論の87%・71%と本文の数値の関係は、今回確認した範囲では確定できなかった。引用する際は、論文の表と図で確認すること。
    - **合成データ**：OSは0.9以上。LLとOS&LLはOSなどより低いが、「通信なし」「全受容」よりは高い。
    - **YCBデータ**：近似手法のうちOSが最も高く、すべての近似手法が「通信なし」より高い。
    - 近似手法の個別の一致率は、取得できた本文には書かれていなかった。

大規模言語モデル（LLM）の世界理解：集合的世界モデル仮説

身体を持たないテキスト処理AIであるLLMが、なぜ世界についての豊かな知識を備えているように見えるのかという問いに対し、CPCは一つの理論的な説明を提案している。共有された記号は、個人の脳内の概念表現（隠れ状態）にトップダウンに働きかけ、その後の内的状態に影響を与える。そして人間社会全体が、無数の身体経験をCPCによって記号空間へと圧縮・符号化し、膨大なテキストコーパスとして蓄積してきたと考えられる。

谷口らは、「LLMは、人間社会が身体経験を通じて集合的に形成した『集合的世界モデル』の統計的近似を、言語データの学習を通じて獲得している」という「集合的世界モデル仮説」を提案している。LLMの言語能力の背後には、人類社会の身体的な意味形成の積み重ねがあるという見方である。

黒板のポイント【これは仮説である】：集合的世界モデル仮説は、現時点では直接の実証的検証が今後の課題とされている。LLMが「世界を理解している」と断定するのではなく、社会の集合的営みの統計的近似という枠組みで解釈する立場として受け止めたい。

6. 実機検証：身体性ロボティクスと共創学習の実験エビデンス（スライド24–27）

理論がここまで揃ったところで、これらの数理モデルが最新のロボティクスやAIの実機でどこまで実証されているか、具体的なエビデンスを見ていく。数理モデルの一部は、実機ロボットや人間被験者を交えた小さな課題で確かめられ始めている。ただし、どれも初期的な段階で、理論全体の証明ではない。

ヒューマノイドロボット iCub による到達運動制御

オリバーらによるヒューマノイドロボット iCub の実験実装である（2020・2021年）。FEPでは、脳は予測と感覚のズレ（予測誤差）を減らし続けると考え、その方法は2つある。予測を直す「知覚」と、自分が動いて感覚を予測に合わせる「行動」である。iCub は、頭部ステレオカメラによる視覚と、関節の角度を感じる固有受容感覚という2つの感覚を持ち、両方のズレを同時に減らすよう腕を動かした。

- **到達精度**：目標へ手を届かせる平均誤差は、従来の逆運動学（目標から関節角を逆算する制御）の 1.69 cm に対し、0.67 cm であった。
- **追従運動**：頭で物体を追う動きも、同じ原理で実現している。

知覚と運動が、予測誤差の最小化という一つの原理で動いたことを示す実装である。

実機ロボットアームによる認知的探索（鍋とボール課題）

藤井・村田らによる実機ロボットアーム制御の研究である（2025・2026年）。能動的推論では、行動を選ぶとき、将来の予測誤差がどれだけ減りそうかをEFEで見積もる。EFEには、目標に近づく度合い（実利的価値）に加え、新しい情報が得られる度合い（認識的価値）が含まれる。

- **見えないものを確かめに行く行動**：蓋の閉まった鍋の中にボールがあるかは見えない。目標の重みを下げると、ロボットは中を確かめるために蓋を開けた。
- **計算コストの削減**：EFEの計算は重いため、連続的な運動を少数の「抽象行動」にまとめ、すべての候補となる抽象行動の評価時間を、行動列を逐次入力する従来の深層能動的推論の 71.8 ms から 2.37 ms に短縮した。
- **課題成功率**：ボールと蓋の課題全体の成功率は、目標条件付き拡散ポリシー（GC-DP）に基づく手法の 24.4% に対し 70.7% であった。

人間とAIの共創学習（Co-Creative Learning）：69名オンライン実験

奥村らによる、人間とAIの共創学習に関する実験である（2025/2026年）。90名を募集し、除外後の解析対象は69名（MH群26名、常に受け入れる群20名、常に断る群23名）である。被験者はAIとペアを組み、「切り込みのある円」に名前を付ける共同注意名付けゲーム（JA-NG）を行った。

- **相補的部分観測**：人とAIはそれぞれ一部の情報しか見えない。人は「明るさ・向き・大きさ」、AIは「明るさ・色」を観測し、二人の情報を合わせるとよりよい名付けができる状況を設定した。
- **受容判断の理論的整合**：相手の提案を受け入れるかどうかは「その名前が自分の見え方に合うか」で決まる。この理論に沿って動くAIと組むと、人もその予測に沿って受け入れたり断ったりした。人間の受容行動は、MH受容確率と正の相関を示した。
- **AI側の名付け**：二人の情報を合わせた妥当な名付けに、常に断るAIより有意に近づいた。**ただし、常に受け入れるAIと比べると、はっきりした差は見つからなかった。**「同じだった」と言えるわけではなく、この人数では差を示せなかった、ということである。

- **人間側の指標**：全体の検定は有意水準すれすれ（p=0.053、p=0.052）だったが、群間の比較は多重比較の補正後に有意ではなかった。
- **要旨との食い違い**：arXivの要旨には「カテゴリ化精度が有意に改善した」とあり、本文の人間側の結果と食い違って見える。発表では、本文の数字に合わせて「人間側は有意差なし」と述べる。

黒板のポイント【何を言えて、何を言えないか】：これは集合的予測符号化の仮説全体の証明ではなく、その中核の仕組みを小さな課題で確かめた初期的な実験である。価値観や目標が一致することを示したものでもない。AIを従わせるのではなく共に学ぶための、土台となる仕組みを確かめた段階である。

移動ロボット Kachaka による生活空間画像 MHNG（実験設計の報告）

出原らによる2025年の研究は、2台のロボットが同じ物の名前を共有できるかを調べるものである。仕組みはMHNGで、1台が名前を言い、もう1台が自分の見え方に照らして受け入れるか断る。相手の内部は一切見ない。理論上は、これを交代しながら繰り返すと、互いの内部を見ずに名前がそろっていくことが知られている（分散ベイズ推論）。

黒板のポイント【この予稿には結果が載っていない】：載っているのは実験の設計である。Preferred Robotics 社の自律移動ロボット「Kachaka」2台を人が操作して生活空間で画像を集め、セグメンテーションモデル（SAM）で物体を切り出した。予稿には「詳細な実験条件、実験結果等は口頭発表にて報告する」とあり、結果は口頭発表で報告されるとされている。ロボット自身が探索し、共同注意を作ることはこれからの課題である。理論を実世界で確かめる試みは、まだ始まったばかりである。

黒板のポイント【講師の見解：分布外と人の介入余地】：モデルは、学習で見た世界の外では予測が外れやすくなる。生活空間は、その外に出やすい場所である。だからこそ、人が確認し、止め、直せる余地を残すことが欠かせない。

7. 結び：多層ループの総括と人・AI共生知能（スライド28–30）

多層ループの総括

黒板全体の総括大図解が示すのは、心、対話、社会、そしてAIを縦横無尽に貫く「相互適応の壮大な見取り図」である。個人の脳における知覚と能動的推論による適応（FEP）。対面コミュニケーションにおける予測誤差修正と一般化同期。見知らぬ他者との協調を支える環境デオンティック・キューへの推論外部化（ROE）。そして社会全体で世界モデルを編み上げる言語の創発（CPC）。これらは決してバラバラの現象ではない。生命と社会が、エントロピーの増大に抗い、変分自由エネルギーを低減させ続ける多層的な自己組織化のループとして、統一的に理解することができる。

共生的AIアライメント（Symbiotic Alignment）

出典：Taniguchi et al., “Symbiotic Alignment via Collective Predictive Coding: A Theoretical Framework for Co-Creative Human-AI Ecosystems,” *Artificial Life* 32(3):270–298 (2026).

この多層ループの視点から現代のAI技術を見つめ直すと、従来の「AIアライメント」に対する根本的なパラダイムシフトが要請される。

- **従来モデル（単方向のアライメント）**：人間が神のように一方的なルールや報酬を与え、AIを従わせる。ただし人間の基準も偏りうるため、価値を一点に揃えるだけでは価値が均質化してしまう。現実にも、高度なAIとの対話の中で、人間の側の価値や判断の枠組みが変わりつつある。
- **共生的AIアライメント**：谷口教授らが提案する双方向の適応思想である。人間とAIが互いに影響を与え合い、それぞれの生成モデルを更新する。互いの理解を深めつつ、全員が同じ意見になるのではなく、多様な見方や自律性を保ったまま、集団全体の自由エネルギーを低減していく。より望ましい社会秩序を共に育てていく。これが次世代のAI研究開発の目指す方向ではないか、と講師は考えている。

信頼相当性（Trustworthiness）と Fail-smart

最後の黒板の中央にある盾は「信頼相当性」、つまりデータによる裏付けである。周りから迫る矢は「盲目的信頼・過信」で、AIの答えを中身も考えずに受け入れてしまう危うさである。

では、盾さえあれば安心なのだろうか。法律の研究者で、AIと社会の関係に詳しい大阪大学の工藤郁子さんの指摘を紹介したい。裏付けだけを追いかけると、限界や矛盾が出てくる。信頼には、いちいち検証しなくても前に進める長所もある。つまりこの盾は、信頼を捨てるためのものではない。どこを検証し、どこを信頼に委ねるかを見極める道具だと、講師は考えている。

盾の右にある「Fail-smart」は「賢く失敗する」という意味で、IT業界やスタートアップの世界ではおなじみの言葉である。これは講師の補足だが、工藤さんは、人とAIが共生する社会でも「より良く間違う」ことをどう実践するかが、学ぶべきポイントだと述べている。間違いを振り返り、次に生かす。そんな決定のあり方を、一緒に考えていきたい。

本日の結論：「AIの価値は人の代替ではない。共に意味と目的を育む共生知能の創発にある。」従わせるのではなく、共に育つ。谷口忠大の集合的予測符号化とも重なる考え方である。